

Este trabalho esta disponível no git: <https://github.com/echer/26E2-infnet-trabalho-pd-mineracao-de-dados-para-series-temporais.git>.

Este trabalho tem como objetivo aplicar técnicas de mineração de dados para séries temporais utilizando a plataforma KNIME. Foram utilizadas técnicas de análise exploratória, decomposição temporal, autocorrelação e modelagem ARIMA para análise e previsão de séries temporais.

A base de dados escolhida contém informações de pedidos realizados em um restaurante ao longo do tempo. Essa base foi selecionada por possuir uma variável temporal (Order Date) e diversas variáveis quantitativas relacionadas às vendas, tornando-a adequada para análise de séries temporais.

Além disso, a base apresenta forte comportamento sazonal, variações de demanda e tendência temporal, características importantes para aplicação de técnicas de previsão e decomposição temporal.

Dataset

Para este trabalho estou utilizando o dataset do kaggle `Takeaway Food Orders` disponível no link: <https://www.kaggle.com/datasets/henslersoftware/19560-indian-takeaway-orders>.

Estrutura dos dados

Variável	Tipo	Descrição
Order Number	Discreta	Número identificador do pedido
Order Date	Temporal	Data e hora do pedido
Item Name	Categórica	Nome do produto vendido
Quantity	Discreta	Quantidade vendida do item
Product Price	Contínua	Preço unitário do produto
Total Products	Discreta	Quantidade total de produtos no pedido
Order ID	Discreta	Identificador único do pedido

Variável	Média	Desvio Padrão	Mínimo	Máximo
Order Number	9.115,548	4.052,163	630	16.118
Quantity	1,247	0,732	1	32
Product Price	5,177	3,260	0,5	17,95
Total Products	7,125	3,375	1	60
Order ID	15.185,998	6.088,428	2.096	25.583

As variaveis `Order Number` , `Order ID` , `Total Products` foram removidas no knime.

Column Filter

Column filter

Manual
Wildcard
Regex
Type

Search

Aa

Excludes

Order Number

Total products

Order ID

Includes

Order Date

Item Name

Quantity

Product Price

Any unknown column

Discard

Apply and Execute

Apply

Foi criado uma nova coluna com o total chamada: revenue , multiplicando o Quantity pelo Product Price

Dialog - 3:10 - Math Formula (cria coluna valor vendido)

File

Math Expression

Flow Variables

Job Manager Selection

Memory Policy

Column List

ROWINDEX

ROWCOUNT

Quantity

Product Price

Flow Variable List

Category

All

Description

Function

ROWCOUNT

ROWINDEX

pi

e

COL_MIN(col_name)

COL_MAX(col_name)

COL_MEAN(col_name)

COL_MEDIAN(col_name)

COL_SUM(col_name)

COL_STDDEV(col_name)

COL_VAR(col_name)

Expression

1

\$Quantity*\$Product Price\$

Append Column:

revenue

Replace Column:

Product Price

Convert to Int

A partir da coluna order date foi criado as colunas: day_of_week , month , day_of_year .

Date&Time Part Extractor

×

Date&time column

Order Date

▼

Field

Column name

Day of Week (Name)▼

day_of_week

↑

↓

🗑️

Field

Column name

Month (Number) ▼

month

↑

↓

🗑️

Field

Column name

Day of Year ▼

day_of_year

↑

↓

🗑️

⊕ Add field

Os dados da coluna `order_date` também foi modificada removendo a hora e deixando apenas a data. Antes `yyyy-MM-dd HH:mm`, após apenas `yyyy-MM-dd`.

Date&Time to String

×

Date&time columns

Manual

Wildcard

Regex

Type

🔍 Search

Aa

Excludes

Includes

No columns in this list.

Any unknown column

>

>>

<

<<

Order Date

Locale

English (United States) ▼

Output format

yyyy-MM-dd 🗑️

Output columns

Replace

Append with suffix

As colunas `order_date` e `revenue` foram renomeadas para `data`, `valor`.

Column Renamer

Column

Order Date

New name

data

Column

revenue


New name

valor

+

Add column

E esta foi a análise inicial realizada no knime:



A partir dos dados prontos foram feitos a decomposição manual da coluna valor nas colunas tendencia , sem_tendencia , sazonalidade e residuo .

► 1: Output data

📄 Flow Variables


Rows: 1216

Columns: 7

Table

Statistics

#	RowID	data Date	day_of_week String	vendas Number (Float)	tendencia Number (Float)	sem_tendencia Number (Float)	sazonalidade Number (Float)	residuo Number (Float)
49	Row48	2016-04-22	Friday	386.1	179.782	206.318	500.709	-294.39
50	Row49	2016-04-23	Saturday	453.5	191.612	261.888	981.178	-719.29
51	Row50	2016-04-24	Sunday	330.55	200.425	130.125	16.61	113.515
52	Row51	2016-04-25	Monday	33.05	198.002	-164.952	-392.791	227.839
53	Row52	2016-04-26	Tuesday	42.25	197.95	-155.7	-408.412	252.712
54	Row53	2016-04-27	Wednesday	101.45	193.327	-91.877	-363.498	271.621
55	Row54	2016-04-28	Thursday	146.2	191.497	-45.297	-270.656	225.359
56	Row55	2016-04-29	Friday	239.05	194.182	44.868	500.709	-455.84
57	Row56	2016-04-30	Saturday	288.9	195.745	93.155	981.178	-888.023
58	Row57	2016-05-01	Sunday	57.2	190.198	-132.998	16.61	-149.609
59	Row58	2016-05-02	Monday	365.95	198.613	167.337	-392.791	560.128
60	Row59	2016-05-03	Tuesday	106.25	201.66	-95.41	-408.412	313.002



Existe sazonalidade nas vendas do restaurante ao longo da semana?

A análise temporal permitiu identificar padrões repetitivos de consumo, mostrando quais dias da semana apresentam maior ou menor volume de vendas. No presente trabalho, observou-se forte sazonalidade semanal, com aumento significativo das vendas aos finais de semana, principalmente sexta e sábados.

Rows: 1216 | Columns: 6

#	RowID	data Date	day_of_week String	vendas Number (Float)	tendencia Number (Float)	sem_tendencia Number (Float)	sazonalidade ↓
1153	Row11	2019-06-01	Saturday	2,198.25	1,338.817	859.433	981.178
1160	Row11	2019-06-08	Saturday	2,341.6	1,306.603	1,034.997	981.178
1167	Row11	2019-06-15	Saturday	2,519.55	1,273.535	1,246.015	981.178
1174	Row11	2019-06-22	Saturday	1,635.95	1,246.257	389.693	981.178
1181	Row11	2019-06-29	Saturday	2,311.75	1,212.162	1,099.588	981.178
1188	Row11	2019-07-06	Saturday	2,538.65	1,245.352	1,293.298	981.178
1195	Row11	2019-07-13	Saturday	1,651.6	1,191.195	460.405	981.178
1202	Row12	2019-07-20	Saturday	1,927.15	1,156.098	771.052	981.178
1209	Row12	2019-07-27	Saturday	2,366.3	1,194.285	1,172.015	981.178
1216	Row12	2019-08-03	Saturday	2,126.2	1,161.952	964.248	981.178
7	Row6_J	2015-10-02	Friday	117.85	②	②	500.709
13	Row12	2016-03-11	Friday	19.75	②	②	500.709
17	Row16	2016-03-18	Friday	729.95	②	②	500.709
24	Row23	2016-03-25	Friday	240.15	②	②	500.709
31	Row30	2016-04-01	Friday	360.1	143.747	216.353	500.709
37	Row36	2016-04-08	Friday	224.1	167.015	57.085	500.709
43	Row42	2016-04-15	Friday	172.55	199.033	-26.483	500.709
49	Row48	2016-04-22	Friday	386.1	179.782	206.318	500.709
56	Row55	2016-04-29	Friday	239.05	194.182	44.868	500.709

As vendas do restaurante apresentam tendência de crescimento ou queda ao longo do tempo?

A decomposição temporal permitiu identificar a tendência da série temporal utilizando médias móveis. Com isso, foi possível verificar o comportamento de longo prazo das vendas e confirmar uma tendencia de crescimento no faturamento ao longo da serie temporal.



Processo Estocástico

Processo estocástico é um processo que possui comportamento aleatório ao longo do tempo, apresentando incertezas e variações imprevisíveis. No nosso caso as vendas do restaurante podem ser consideradas um processo estocástico, pois sofrem influência de diversos fatores externos, como clima, promoções, feriados e comportamento dos clientes.

Processo Determinístico

Processo determinístico é um processo cujo comportamento pode ser previsto de maneira exata a partir de regras fixas, sem presença de aleatoriedade. Nesse tipo de processo, os mesmos valores de entrada sempre produzem os mesmos resultados, é como se uma variável tenha uma forte correlação com a outra, quando uma aumenta a outra também ou quando diminui.

Sazonalidade Estocástica

Sazonalidade estocástica ocorre quando os padrões sazonais apresentam comportamento repetitivo, porém com intensidade variável ao longo do tempo. No nosso caso, por exemplo, os finais de semana normalmente possuem maior volume de vendas, mas essa intensidade pode variar entre diferentes períodos.

Sazonalidade Determinística

Sazonalidade determinística ocorre quando os padrões sazonais se repetem de forma fixa e previsível ao longo do tempo, mantendo comportamento praticamente constante entre os ciclos temporais.

Sazonalidade aditiva vs multiplicativa

Na sazonalidade aditiva, a amplitude do componente sazonal permanece aproximadamente constante ao longo do tempo. O efeito sazonal é somado à tendência da série temporal ($Y=T+S+R$).

Na sazonalidade multiplicativa, o efeito sazonal varia proporcionalmente ao nível da série temporal. Quanto maior a série, maior tende a ser a amplitude da sazonalidade.


Gráficos

Foram construídos gráficos temporais utilizando a variável temporal data no eixo X e as variáveis quantitativas no eixo Y, permitindo analisar o comportamento temporal das vendas, tendência, sazonalidade e ruído da série ao longo do tempo. Os gráficos mostraram crescimento gradual das vendas e forte comportamento sazonal semanal.

Gráfico ACF

Foram observados picos significativos nos lags 7, 14, 21 e 28, evidenciando comportamento sazonal semanal.

Foram utilizados gráficos de autocorrelação (ACF Plot) para analisar a dependência temporal das variáveis ao longo do tempo.



Rows: 465 | Columns: 5

Table  Statistics 

☐	#	RowID	First column name String	Second column name String	Correlation value Number (Float)
☐	1	Row0	vendas	vendas(-1)	0.468
☐	2	Row1	vendas	vendas(-2)	-0.051
☐	3	Row2	vendas	vendas(-3)	-0.252
☐	4	Row3	vendas	vendas(-4)	-0.247
☐	5	Row4	vendas	vendas(-5)	-0.053
☐	6	Row5	vendas	vendas(-6)	0.453
☐	7	Row6	vendas	vendas(-7)	0.809
☐	8	Row7	vendas	vendas(-8)	0.455
☐	9	Row8	vendas	vendas(-9)	-0.072
☐	10	Row9	vendas	vendas(-10)	-0.268
☐	11	Row10	vendas	vendas(-11)	-0.249
☐	12	Row11	vendas	vendas(-12)	-0.055
☐	13	Row12	vendas	vendas(-13)	0.436
☐	14	Row13	vendas	vendas(-14)	0.798
☐	15	Row14	vendas	vendas(-15)	0.426
☐	16	Row15	vendas	vendas(-16)	-0.076
☐	17	Row16	vendas	vendas(-17)	-0.266
☐	18	Row17	vendas	vendas(-18)	-0.254
☐	19	Row18	vendas	vendas(-19)	-0.043
☐	20	Row19	vendas	vendas(-20)	0.445
☐	21	Row20	vendas	vendas(-21)	0.773
☐	22	Row21	vendas	vendas(-22)	0.405
☐	23	Row22	vendas	vendas(-23)	-0.1
☐	24	Row23	vendas	vendas(-24)	-0.282
☐	25	Row24	vendas	vendas(-25)	-0.252
☐	26	Row25	vendas	vendas(-26)	-0.05
☐	27	Row26	vendas	vendas(-27)	0.448
☐	28	Row27	vendas	vendas(-28)	0.763

Gráfico PACF

O gráfico de autocorrelação parcial (PACF) foi utilizado para identificar quais defasagens possuem influência direta sobre a série temporal de vendas.

Os resultados mostraram maior influência nos lags 1, 7, 14, 21 e 28, evidenciando forte sazonalidade semanal e dependência temporal direta entre observações separadas por múltiplos de 7 períodos.

Os coeficientes intermediários apresentaram baixa magnitude, indicando que boa parte da dependência temporal da série é explicada pela estrutura sazonal semanal.

1: Model for Predictor

2: Coefficients and Statistics

Flow Variables

Rows: 31 | Columns: 5

☐	#	RowID	Variable [String]	Coeff. [Number (Float)]
☐	1	Row1	vendas(-1)	0.159
☐	2	Row2	vendas(-2)	-0.01
☐	3	Row3	vendas(-3)	-0.012
☐	4	Row4	vendas(-4)	0.02
☐	5	Row5	vendas(-5)	-0.022
☐	6	Row6	vendas(-6)	0.072
☐	7	Row7	vendas(-7)	0.28
☐	8	Row8	vendas(-8)	0.095
☐	9	Row9	vendas(-9)	-0.072
☐	10	Row10	vendas(-10)	-0.029
☐	11	Row11	vendas(-11)	0.018
☐	12	Row12	vendas(-12)	-0.041
☐	13	Row13	vendas(-13)	-0.03
☐	14	Row14	vendas(-14)	0.238
☐	15	Row15	vendas(-15)	-0.015
☐	16	Row16	vendas(-16)	0
☐	17	Row17	vendas(-17)	0.035
☐	18	Row18	vendas(-18)	-0.015
☐	19	Row19	vendas(-19)	0.016
☐	20	Row20	vendas(-20)	0.028
☐	21	Row21	vendas(-21)	0.133
☐	22	Row22	vendas(-22)	-0.058
☐	23	Row23	vendas(-23)	-0.059
☐	24	Row24	vendas(-24)	-0.008
☐	25	Row25	vendas(-25)	0.008
☐	26	Row26	vendas(-26)	-0.043
☐	27	Row27	vendas(-27)	0.066
☐	28	Row28	vendas(-28)	0.124

Gráfico decomposição

A série temporal foi decomposta manualmente em três componentes principais: Tendência, sazonalidade e resíduo.

A tendência foi calculada utilizando média móvel de 30 períodos. A sazonalidade foi obtida agrupando os valores detrended (sem_tendencia) por dia da semana (day_of_week). O resíduo foi calculado pela diferença entre a série original e os componentes

estimados.




Gráfico recomposição

A recomposição da série apresentou valores muito próximos da série original, validando a decomposição realizada.





Gráfico ARIMA

Para escolha do melhor modelo ARIMA foi utilizado o critério AIC (Akaike Information Criterion). O AIC avalia a qualidade do ajuste penalizando modelos excessivamente complexos. Quanto menor o valor do AIC, melhor tende a ser o equilíbrio entre ajuste e simplicidade do modelo.


O modelo ARIMA ajustado apresentou boa aderência à série temporal original, sendo observado que os valores ajustados (“fitted values”) acompanharam adequadamente o comportamento das vendas ao longo do tempo. Isso indica que o modelo conseguiu capturar parte significativa da tendência e sazonalidade presentes na série temporal.

Foram avaliados diferentes modelos ARIMA, incluindo ARIMA(1,1,1), ARIMA(7,1,1) e ARIMA(1,1,7). O modelo ARIMA(7,1,1) apresentou melhor desempenho considerando os critérios estatísticos, ajuste visual da série e análise residual.



Line Plot

Open in new window



A análise dos resíduos do modelo ARIMA mostrou comportamento aproximadamente aleatório ao longo do tempo, com oscilações em torno de zero e ausência de padrões evidentes de tendência ou sazonalidade. Esse comportamento indica que o modelo ARIMA conseguiu capturar adequadamente a estrutura temporal presente na série de vendas. Apesar da presença de alguns picos extremos, os resíduos apresentaram comportamento compatível com ruído branco, validando estatisticamente a qualidade do ajuste do modelo.

Line Plot

Open in new window

